Introduzione alle memorie

Matteo Sonza Reorda

Politecnico di Torino
Dip. di Automatica e Informatica



Introduzione

Ogni sistema di elaborazione contiene dispositivi per la memorizzazione di dati ed istruzioni.

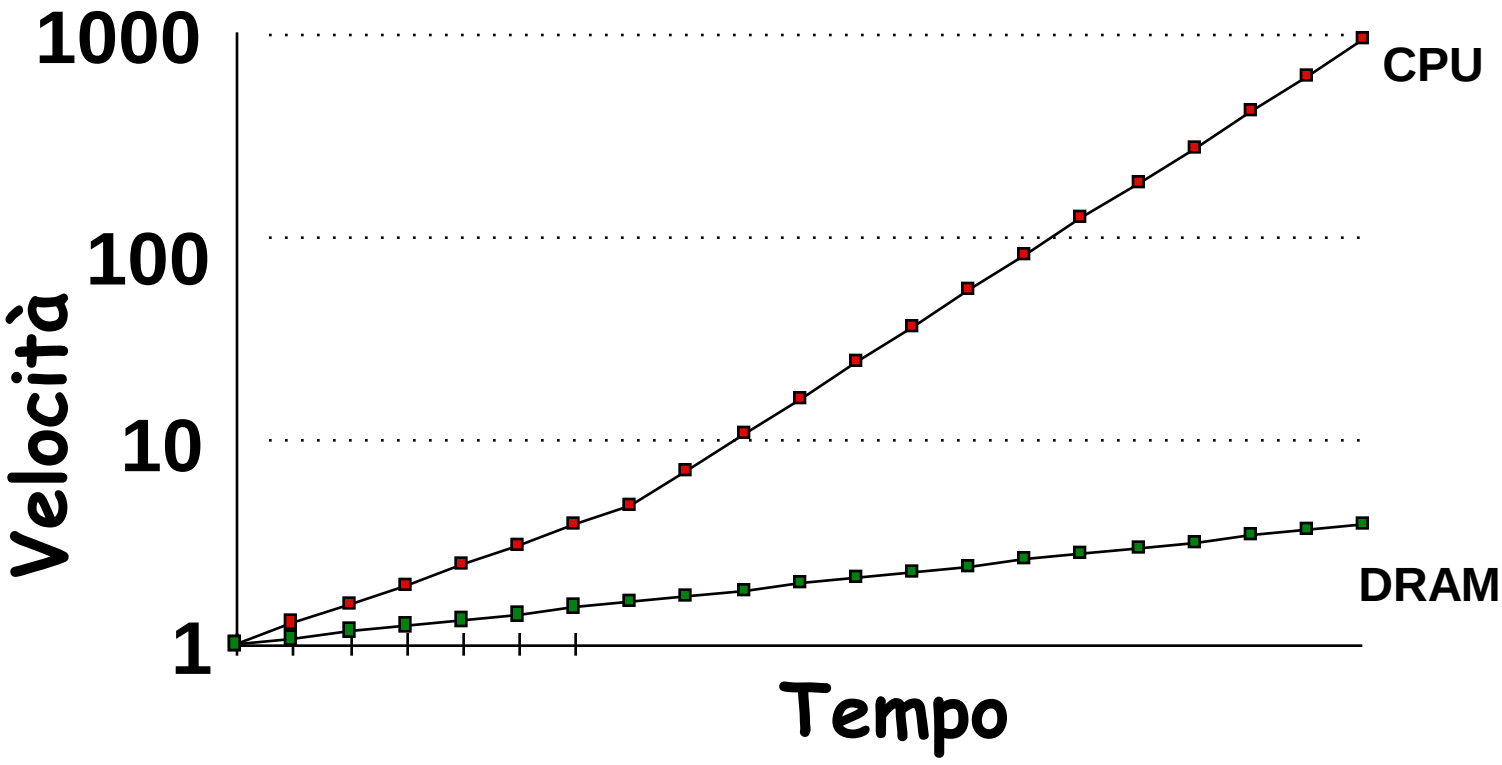
L'insieme di tali dispositivi, e degli algoritmi per la loro gestione, costituisce il *sotto-sistema di memoria*.

Tale sotto-sistema deve essere realizzato in modo che

- **il processore debba attendere il meno possibile per accedere a dati o istruzioni**
- **il costo del sistema di memoria sia minimo (il costo per bit delle memorie è proporzionale alla loro velocità).**

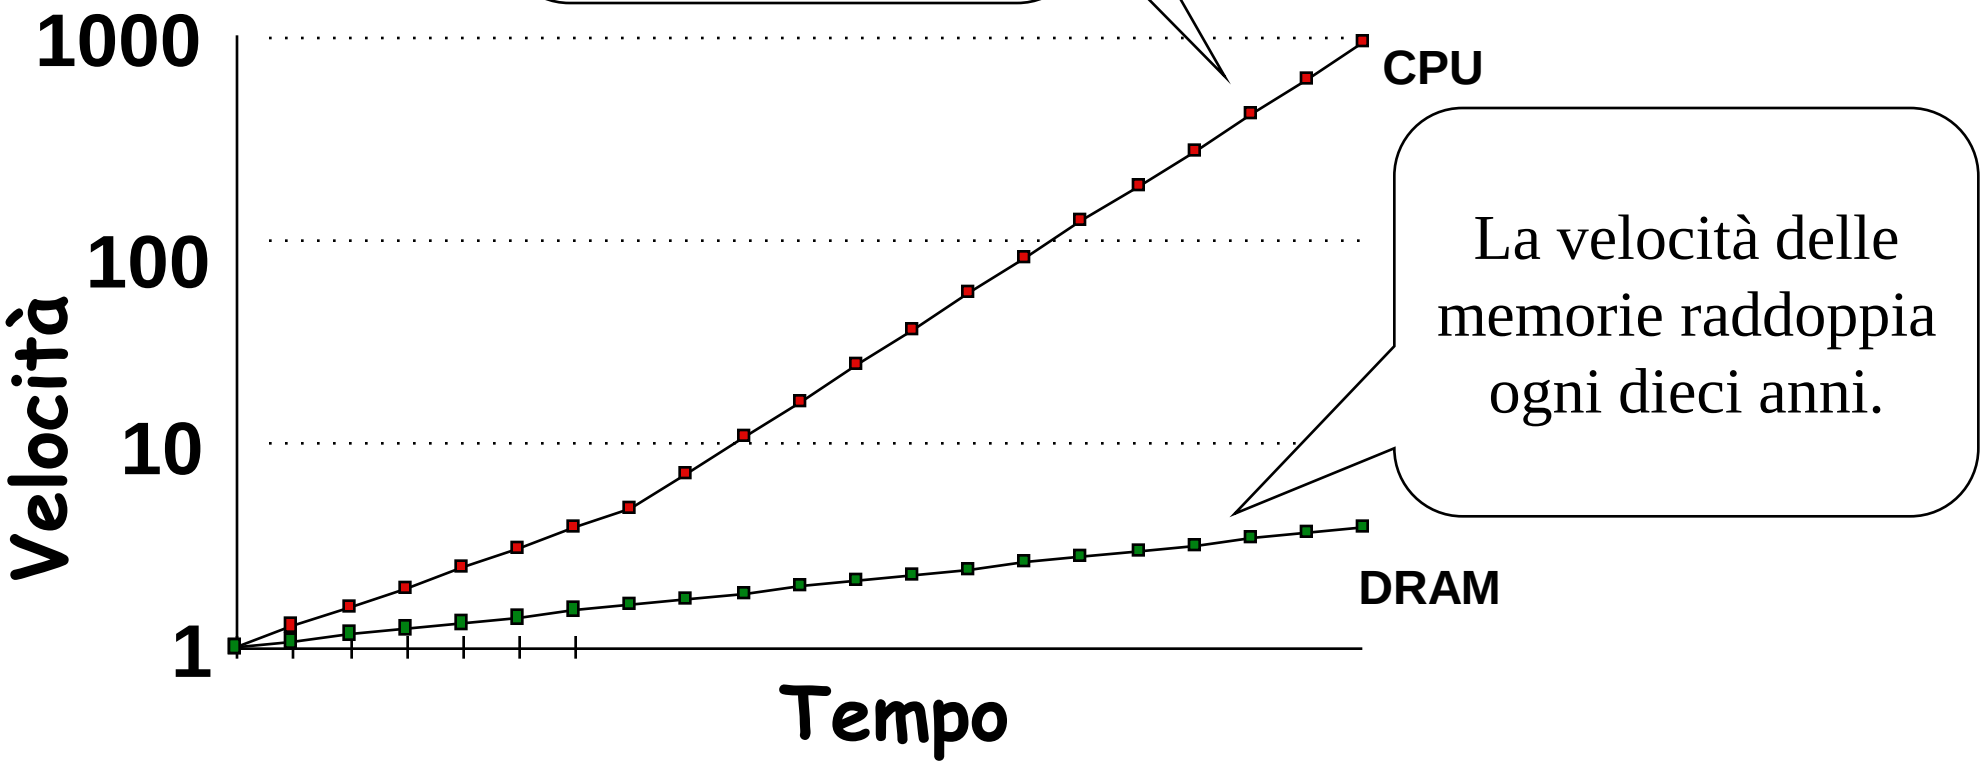
Si deve quindi cercare un compromesso tra il costo del sotto-sistema di memoria e le sue prestazioni.

Velocità del processore/velocità della memoria



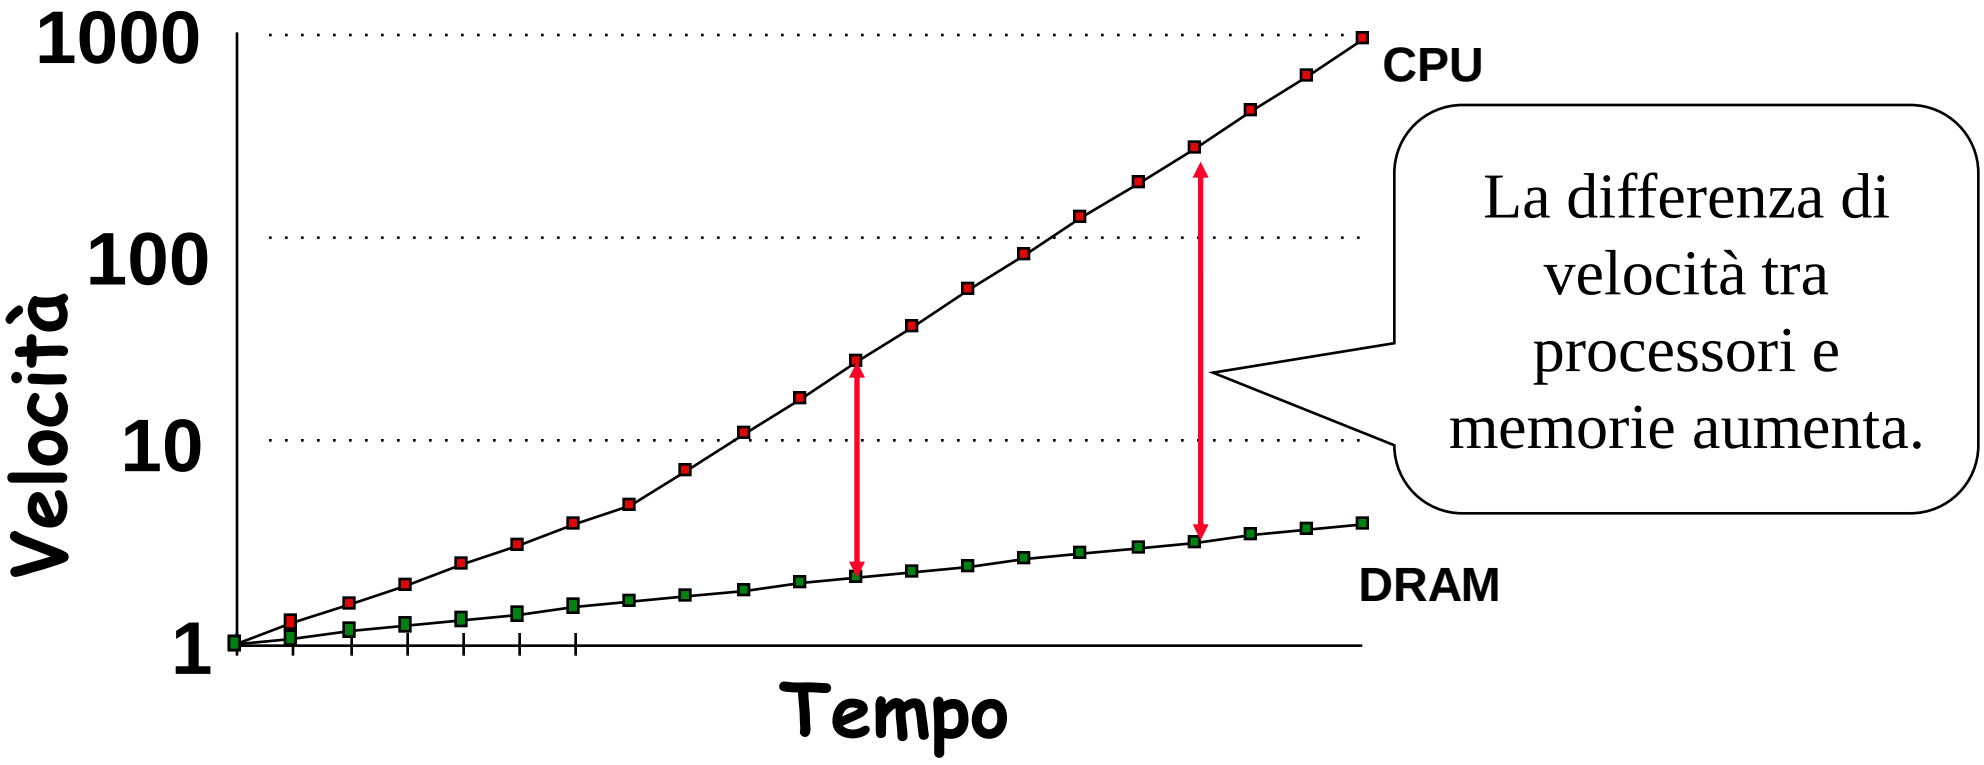
Velocità sore/velocità oria

La velocità dei processori raddoppia ogni anno e mezzo.



La velocità delle memorie raddoppia ogni dieci anni.

Velocità del processore/velocità della memoria



Livelli di memorie

La memoria di un calcolatore è normalmente organizzata in *livelli*.

Il numero di livelli dipende dal tipo di sistema e di applicazione.

Ogni livello è caratterizzato da un diverso tipo di memoria (in termini di velocità e dimensione, e quindi costo).

Obiettivo

Ottimizzare il Sistema di Memoria in modo tale da minimizzare il tempo medio di accesso per i tipici programmi che utilizziamo (*workload*):

- **Le informazioni sono distribuite in modo dinamico tra i vari livelli a seconda della relativa frequenza di accesso**
- **In tal modo si raggiungono prestazioni comparabili con quelle della memoria più veloce, a prezzi comparabili con quelli della memoria più lenta.**

Principio di località dei riferimenti

Un riferimento in memoria tende ad essere ripetuto dopo poco tempo:

- **Località temporale**

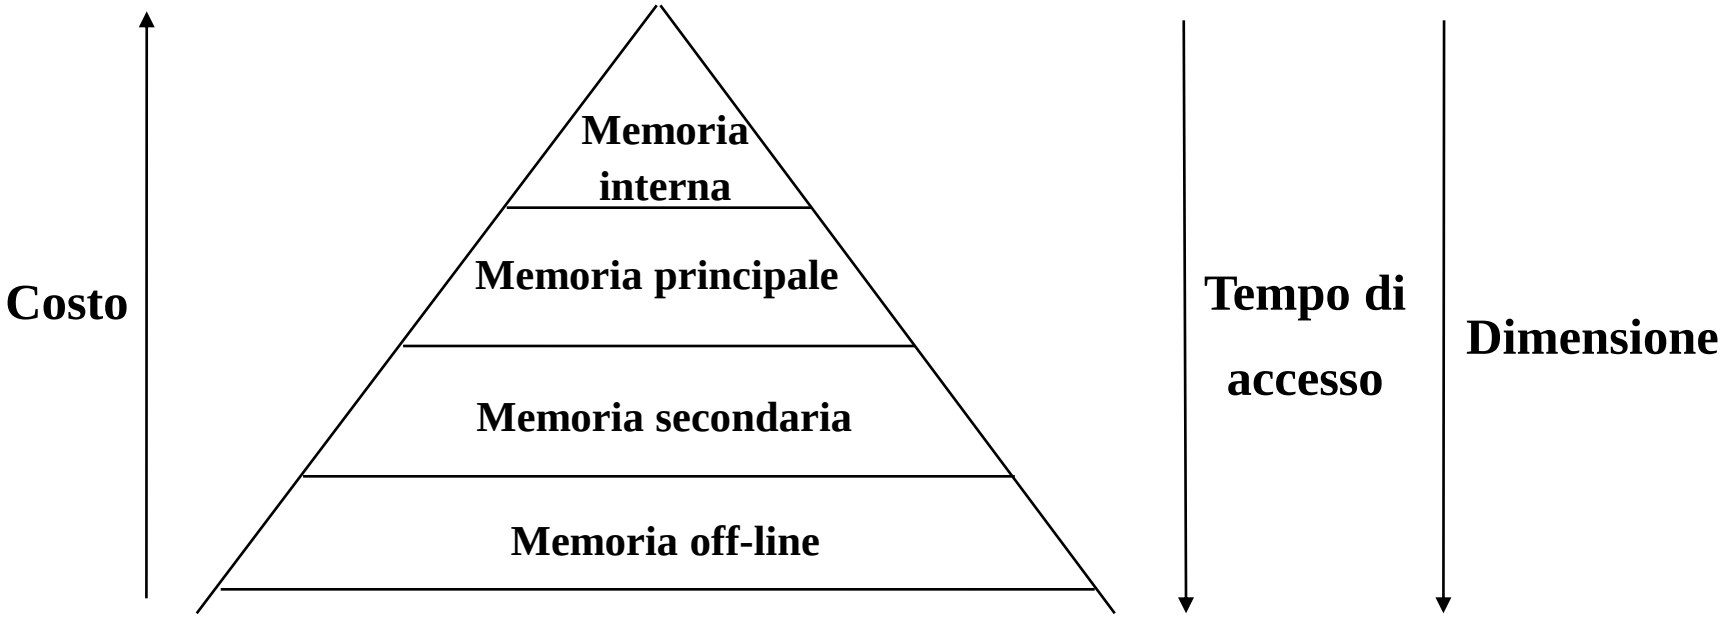
Un riferimento in memoria tende ad essere a locazioni vicine a quelle usate recentemente

- **Località spaziale.**

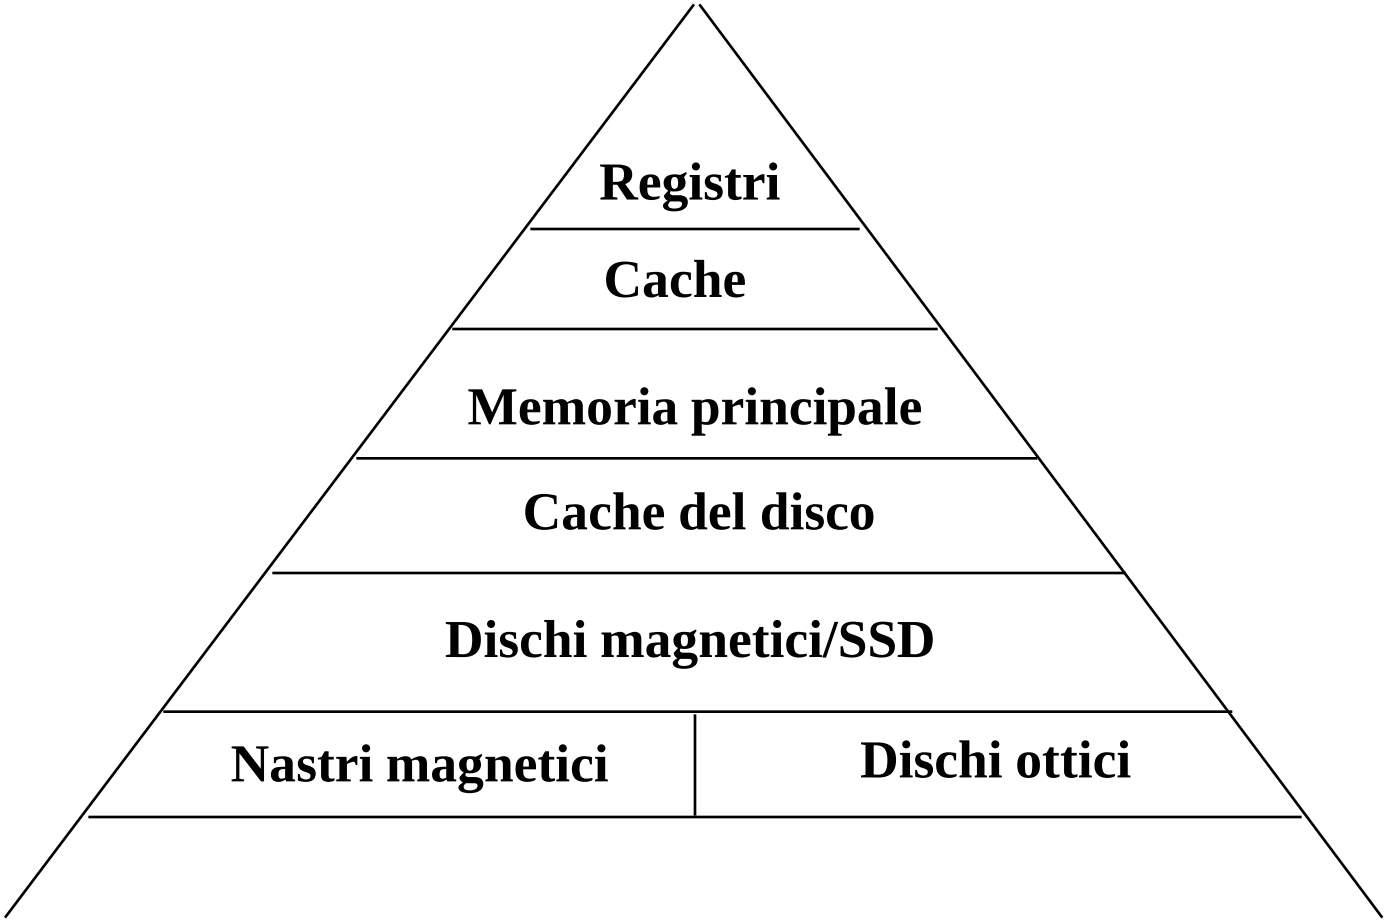
Implicazioni del principio di località

- **Posso utilizzare piccole memorie veloci per mantenere i riferimenti in memoria più utilizzati dal processore**
- **Se i riferimenti utilizzati non possono essere soddisfatti nella memoria veloce creo un secondo livello di memoria un po' più grande e un po' meno veloce**
- **Posso reiterare questo ragionamento per *n* livelli di memoria:**
  - **Gerarchia di memoria**

Gerarchia di memoria



Situazione attuale



Memoria interna alla CPU

Corrisponde ai registri interni della CPU.

È caratterizzata da:

- **alta velocità (comparabile con quella del processore): i tempi di accesso sono dell'ordine dei ns**
- **limitate dimensioni (al più qualche Kbyte).**

È di solito realizzata tramite celle di *RAM statica*.

Memoria principale

Ha dimensioni molto maggiori (da qualche Mbyte fino a qualche Gbyte) ma tempi di accesso più elevati, dell'ordine delle decine di ns.

È accessibile in modo diretto tramite indirizzi.

È normalmente realizzata sotto forma di circuito integrato.

È di solito realizzata tramite circuiti di *RAM dinamica*.

Memoria secondaria

Ha dimensioni e tempi di accesso ancora maggiori, dell'ordine delle decine di ms.

Ha dimensioni che possono arrivare ai Tbyte.

Viene usata per memorizzare dati e programmi non immediatamente richiesti dal processore.

L'accesso è gestito da appositi programmi di interfaccia.

È normalmente realizzata sotto forma di *dischi magnetici* o memorie *Flash (*anche note come Solid State Disk, o SSD*),* o combinazioni dei due.

Le informazioni memorizzate nella memoria secondaria non vengono perse allo spegnimento del sistema.

Memoria Off-line

Permette di memorizzare grandi moli di dato (Pbyte) con tempi di accesso elevati (decine di secondi).

In taluni casi l'accesso alla memoria off-line richiede l'intervento di un operatore.

Di solito è composta da *dischi ottici* o *nastri*.

Cache

Le *cache* sono memorie estremamente veloci che si interpongono tra il processore e la memoria principale.

All'interno di una cache risiedono temporaneamente i dati/programmi utilizzati in quel momento.

Il loro uso è trasparente al programmatore e al Sistema Operativo.

Le cache permettono di aumentare la velocità di accesso ai dati nella memoria principale senza ricorrere per essa a memorie di tipo più costoso.

Strategia generale

Nella progettazione di un sistema di memoria vengono tenuti in conto i seguenti punti:

- **conviene che il sistema complessivo sia composto da memorie di tipo e costo diversi, rispondenti ai diversi usi che della memoria vengono fatti (*gerarchia di memoria*)**
- **la gestione della memoria deve essere il più possibile trasparente per il programmatore e l'utente (*memoria virtuale*)**
- **se il sistema è di tipo *multiprocessore*, ogni processore deve poter lavorare con la memoria al massimo della velocità e senza interferire con il lavoro degli altri.**

Classificazione delle tecnologie di memoria

È basata su vari parametri:

- **costo**
- **velocità**
- **modi di accesso**
- **alterabilità**
- **durevolezza del contenuto**
- **affidabilità**
- **caratteristiche fisiche.**

Costo

Comprende anche il costo della circuiteria ed eventualmente del software per la gestione delle interfacce necessarie all'uso della memoria.

È normalmente misurato in dollari/bit o $/Mbyte.

Velocità

Si esprime attraverso tre parametri

- **il tempo di accesso**
- **il tempo di ciclo**
- **il tasso di trasferimento.**

Tempo di accesso (o latenza)

È il tempo che intercorre tra l'istante in cui all'unità di memoria giunge la richiesta di eseguire un'operazione (lettura o scrittura), e quello in cui tale operazione è eseguita.

È possibile che il tempo di accesso *in lettura* differisca da quello *in scrittura*.

Il tempo di accesso è di solito inversamente proporzionale al costo della memoria.

Tempo di ciclo

È il tempo che deve intercorrere tra l'inizio di un ciclo di accesso alla memoria e l'inizio del ciclo successivo.

È chiaramente maggiore o uguale del tempo di accesso.

Tasso di trasferimento

È la velocità con la quale i dati possono esser trasferiti verso o dall'unità di memoria.

Per le memorie ad accesso casuale è l'inverso del tempo di ciclo.

Per le altre vale che

$$T_N = T_A + n/R$$

dove

- T_N **è il tempo medio per leggere o scrivere** *n* **bit**
- T_A **è il tempo medio di accesso**
- *n* **è il numero di bit**
- *R* **è il tasso di trasferimento (in bit per secondo, o** *bps***).**

Evoluzione delle memorie

L’evoluzione della tecnologia presenta 2 tendenze:

- **riduzione del *costo* per bit**
- **riduzione (meno marcata) del *tempo di accesso*.**

Modi di accesso

Sono principalmente:

- ***sequenziale*: le informazioni possono essere lette/scritte solo in un ordine prefissato; è il caso dei nastri**
- ***diretto*: ogni blocco ha un indirizzo, e la ricerca nel blocco è sequenziale; è il caso dei dischi magnetici**
- ***casuale*: ogni unità di dato ha un indirizzo, e le informazioni possono essere lette/scritte in qualsiasi ordine; il tempo di accesso è uguale per tutte le locazioni di memoria; è il caso delle memorie a semiconduttore**
- ***associativo:* l'accesso avviene tramite un confronto tra il contenuto di ogni cella e quello specificato in una maschera; è il caso di taluni tipi di cache.**

Alterabilità

Vi sono memorie il cui contenuto può essere scritto una volta sola (*Read Only Memory o ROM)*.

In alcuni casi il contenuto di una memoria ROM può essere modificato off-line (*Programmable ROM o PROM*).

Durevolezza del contenuto: Destructive Readout

Vi sono alcune tecnologie particolari (ad esempio le RAM dinamiche), nelle quali l'operazione di lettura causa la cancellazione del dato memorizzato (*Destructive Readout o DRO)*.

In tal caso dopo ogni lettura è necessario eseguire un'operazione di riscrittura del dato.

Quindi in questo caso il tempo di ciclo è maggiore del tempo di accesso.

Durevolezza del contenuto: refreshing

- **In alcune tecnologie (ad esempio quelle delle memorie dinamiche) dopo un certo tempo i bit a 1 si trasformano in 0**
- **Questo effetto si ha ad esempio quando il bit è memorizzato sotto forma di carica all'interno di un condensatore, a causa delle correnti di scarica**
- **È quindi necessario che periodicamente si provveda a leggere ogni bit e a riscrivere i bit con valore 1 (*refreshing*).**

Durevolezza del contenuto: volatilità

Alcune memorie, come quelle RAM, perdono il loro contenuto quando non sono alimentate (memorie *volatili*).

Affidabilità

Le memorie possono essere colpite da due tipi di guasto:

- ***Guasti transitori*: uno o più bit cambiano valore ad un certo istante, ma la memoria continua a funzionare correttamente**
- ***Guasti permanenti*: qualcosa nella memoria smette definitivamente di funzionare.**

L'affidabilità è di solito misurata attraverso i seguenti parametri:

- ***Mean Time To Failure* (MTTF): tempo medio prima di avere un guasto permanente**
- ***Mean Time Between Failures (*MTBF*):* tempo medio tra due guasti transitori consecutivi.**

Altre caratteristiche

- **Tipo della memoria (elettronica, magnetica, meccanica, ottica)**
- **Consumo**
  - **può comportare la necessità di sistemi di raffreddamento**
  - **può essere critico per i sistemi portabili**
- **Portabilità**
- **Robustezza (ad esempio rispetto alle sollecitazioni meccaniche)**
- **Dimensione: dipende dalla densità di immagazzinamento.**